

# DataXperience

---

## Análisis de rentabilidad y riesgo de desabastecimiento en el sector farmacéutico 2025

Sara Sofía Cruz Fandiño  
Martin Felipe Diaz Collas  
Sergio David Vargas Sáenz  
Julián Fernando Gómez Escobar

# PROBLEMA Y OBJETIVOS DEL PROYECTO

Rentabilidad y riesgo de desabastecimiento en el sector farmacéutico colombiano — 2025



## PREGUNTA PRINCIPAL

¿Cómo se relacionan el tipo de institución, el fabricante y la ubicación geográfica con la rentabilidad y el riesgo de desabastecimiento de productos farmacéuticos durante 2025?

## Objetivos específicos

1

### Instituciones

Ventas, rentabilidad y margen bruto según el tipo de institución.

2

### Fabricantes

Concentración de ventas y nivel de rentabilidad por fabricante.

3

### Ubicación geográfica

Diferencias por ciudad y región en ventas, margen y riesgo.

4

### Abastecimiento

Inventario, lead time, riesgo de stockout y productos prioritarios.

# BÚSQUEDA Y OBTENCIÓN DE LOS DATOS



## 1. Fuente de los Datos

Repositorios oficiales en GitHub, APIs REST públicas y Data Lakes de acceso estructurado.



## 2. Justificación de Elección

Alto volumen de registros limpios, alta frecuencia de actualización y relevancia para el análisis predictivo.




## 3. Estrategia de Obtención

Pipeline automatizado en Python con scripts modularizados para ingesta, limpieza y validación continua.

## BÚSQUEDA Y OBTENCIÓN DE DATOS

DataXperience

### 1. FUENTE DE DATOS



**ORIGEN:** Repositorio público GitHub.  
**METODO:** Carga directa vía URL cruda.




AUTOMATION

### 2. JUSTIFICACIÓN TÉCNICA




**CONFIABILIDAD**  
Misma versión de datos para todos.



**AUTOMATIZACIÓN**  
Reproducibilidad y eficiencia en el pipeline.



**INTEGRACIÓN**  
Formato nativo para Pandas.



**ANÁLISIS RÁPIDO**  
Inmediata etapa de limpieza y EDA.


# COMPRENSIÓN DEL CONJUNTO DE DATOS Y VARIABLES

Ventas e inventario de productos farmacéuticos durante 2025

| 1 Contexto operativo | 2 Desempeño financiero | 3 Inventario y abastecimiento |
|----------------------|------------------------|-------------------------------|
| Tipo de institución  | Ventas                 | Inventario (días)             |
| Fabricante           | Costos                 | Lead Time (días)              |
| Región               | Utilidad bruta         | Riesgo de stockout            |
| Canal                | Margen bruto (%)       |                               |
| Línea terapéutica    |                        |                               |

Tres dimensiones conectadas: esta combinación de variables permite relacionar el comportamiento comercial, la rentabilidad y el riesgo de desabastecimiento.

# PROCESO DE LIMPIEZA Y PREPARACIÓN DE LOS DATOS



1

## Duplicados (ID\_Registro)

Eliminados para evitar doble conteo en ventas y utilidad.

2

## Fechas y meses

Normalizados y validados contra la fecha real.

3

## Ciudad y categorías

Unificadas: mayúsculas, tildes, espacios y errores de escritura.

4

## Formatos numéricos

Separador decimal corregido y convertido a tipo numérico.

**Dataset crudo conservado.** La limpieza se trabajó sobre una copia, permitiendo comparar cada transformación.

# VENTAS, INSTITUCIÓN Y FABRICANTE

VENTAS NETAS 2025

Octubre

\$244K

mes con mayores ventas


Junio

\$181K

mes con menores ventas


El comportamiento comercial no fue uniforme durante el año: la variación entre el mes más alto y el más bajo fue de 35%.

Margen bruto promedio por tipo de institución



Cadenas: 40.6% · Clínica: 37.8% · Hospital: 37.7% · Distribuidor: 34.6%


Margen bruto promedio por fabricante




Vitalis: 48.1% · Sanofi: 41.5% · Tecnoquímicas: 40.7% · Genfar: 38.1% · Procaps: 33.0% · MK: 30.0%

## Análisis exploratorio de datos (EDA) — comportamiento comercial y rentabilidad durante 2025

### UBICACIÓN GEOGRÁFICA, INVENTARIO Y LEAD TIME



Centro: \$797K · Occidente: \$591K · Sur: \$430K ·  
Norte: \$398K · Oriente: \$266K



Oriente: 19.1% · Centro: 18.8% · Occidente: 18.4%  
· Sur: 18.3% · Norte: 18.4%

# ANÁLISIS EXPLORATORIO



LEAD TIME → RIESGO



**+0,60**

Asociación positiva moderada:  
mayores tiempos de entrega  
tienden a estar asociados con  
mayor riesgo.

INVENTARIO → RIESGO

**-0,41**

Asociación negativa moderada:  
mayores niveles de inventario  
tienden a estar asociados con  
menor riesgo.



*Las correlaciones muestran asociación, no causalidad.*

# ANÁLISIS ESTADISTICO

## MEDIDAS DE TENDENCIA CENTRAL Y DISPERSIÓN

|                    | Media    | Mediana  | Moda    |
|--------------------|----------|----------|---------|
| Ventas_Netas_USD   | 495.327  | 312.5567 | 62.7748 |
| Utilidad_Bruta_USD | 156.4904 | 115.8156 | 26.4748 |
| Margen_Bruto_Pct   | 0.3806   | 0.3998   | 0.1357  |
| Inventario_Días    | 30.799   | 31.0     | 33.0    |
| Lead_Time_Días     | 5.1023   | 5.0      | 5.0     |
| Riesgo_Stockout    | 0.1894   | 0.1733   | 0.2091  |

Ventas\_Netas tiene el coeficiente de variación mas alto(1.39), es la variable mas dispersa.



Media es mayor que la Mediana en Ventas y Utilidad.

|                    | Desviación estándar | Varianza    | Mínimo    | Máximo     | Rango     | Q1       | Q3       | IQR      | Coeficiente de variación |
|--------------------|---------------------|-------------|-----------|------------|-----------|----------|----------|----------|--------------------------|
| Ventas_Netas_USD   | 688.9173            | 474607.1068 | 13.9364   | 11872.2394 | 11858.303 | 176.4398 | 561.3124 | 384.8726 | 1.3908                   |
| Utilidad_Bruta_USD | 145.02              | 21030.7905  | -348.8216 | 2681.7326  | 3030.5541 | 71.53    | 191.3677 | 119.8377 | 0.9267                   |
| Margen_Bruto_Pct   | 0.1011              | 0.0102      | -0.0516   | 0.5938     | 0.6454    | 0.3175   | 0.4557   | 0.1382   | 0.2655                   |
| Inventario_Días    | 9.8193              | 96.4178     | 3.0       | 68.0       | 65.0      | 24.0     | 37.0     | 13.0     | 0.3188                   |
| Lead_Time_Días     | 2.3085              | 5.3291      | 1.0       | 17.0       | 16.0      | 3.0      | 7.0      | 4.0      | 0.4524                   |
| Riesgo_Stockout    | 0.12                | 0.0144      | 0.0215    | 2.19       | 2.1685    | 0.1203   | 0.2299   | 0.1096   | 0.6332                   |



# ANÁLISIS ESTADISTICO

## ASIMETRÍA Y VALORES ATÍPICOS



|                  | Skewness | Kurtosis |
|------------------|----------|----------|
| Ventas_Netas_USD | 6.9054   | 73.6726  |
| Riesgo_Stockout  | 4.3096   | 41.6676  |

|   | Variable         | Q1       | Q3       | IQR      | Límite inferior | Límite superior | Cantidad de atípicos |
|---|------------------|----------|----------|----------|-----------------|-----------------|----------------------|
| 0 | Ventas_Netas_USD | 176.4398 | 561.3124 | 384.8726 | -400.8692       | 1138.6213       | 412                  |
| 5 | Riesgo_Stockout  | 0.1203   | 0.2299   | 0.1096   | -0.0441         | 0.3943          | 196                  |

- Ventas Netas: skewness = 6,9 (el promedio está muy inflado por ventas excepcionalmente altas)
- 412 ventas atípicas operaciones grandes que se salen del patrón normal.
- Riesgo Stockout tiene 196 casos atípicos con riesgo inusualmente alto.

# ANÁLISIS ESTADISTICO

## DIFERENCIAS ENTRE INSTITUCIONES, FABRICANTES Y REGIONES

| Tipo_Institución    | Ventas_Netas_USD |          |           | Utilidad_Bruta_USD |          |          | Margen_Bruto_Pct |        |        | Riesgo_Stockout |        |        |
|---------------------|------------------|----------|-----------|--------------------|----------|----------|------------------|--------|--------|-----------------|--------|--------|
|                     | mean             | median   | std       | mean               | median   | std      | mean             | median | std    | mean            | median | std    |
|                     |                  |          |           |                    |          |          |                  |        |        |                 |        |        |
| Cadena de Farmacias | 325.8375         | 228.686  | 284.8409  | 117.3378           | 93.5116  | 84.4029  | 0.4061           | 0.4237 | 0.0945 | 0.1852          | 0.149  | 0.1697 |
| Clínica             | 342.5164         | 242.2745 | 292.6119  | 112.991            | 92.0535  | 78.9599  | 0.3785           | 0.3977 | 0.1002 | 0.1888          | 0.1753 | 0.0961 |
| Distribuidor        | 1084.4968        | 665.1218 | 1329.2225 | 297.5087           | 235.7565 | 236.442  | 0.346            | 0.3681 | 0.1059 | 0.1996          | 0.1908 | 0.0704 |
| Hospital            | 428.1435         | 324.1703 | 347.6326  | 145.121            | 119.7933 | 100.2556 | 0.3784           | 0.3975 | 0.0981 | 0.1879          | 0.1747 | 0.1006 |

- Distribuidor: Vende más del doble del promedio (USD 1.084 vs. USD 495) pero tiene el menor margen (34,6%).

- Región: Centro lidera en ventas (USD 554) y margen (39,6%); Oriente tiene el mayor riesgo (19,3%).

| Región    | Ventas_Netas_USD |          |          | Utilidad_Bruta_USD |          |          | Margen_Bruto_Pct |        |        | Inventario_Días |        |         | Lead_Time_Días |        |        | Riesgo_Stockout |        |        |
|-----------|------------------|----------|----------|--------------------|----------|----------|------------------|--------|--------|-----------------|--------|---------|----------------|--------|--------|-----------------|--------|--------|
|           | mean             | median   | std      | mean               | median   | std      | mean             | median | std    | mean            | median | std     | mean           | median | std    | mean            | median | std    |
|           |                  |          |          |                    |          |          |                  |        |        |                 |        |         |                |        |        |                 |        |        |
| Centro    | 554.395          | 368.0098 | 766.505  | 187.1528           | 142.9642 | 170.4865 | 0.3962           | 0.4146 | 0.0964 | 30.5892         | 30.0   | 9.8238  | 5.1312         | 5.0    | 2.2862 | 0.1928          | 0.1747 | 0.1321 |
| Norte     | 431.97           | 272.8084 | 527.9881 | 132.8447           | 99.2817  | 114.1247 | 0.3714           | 0.3934 | 0.1032 | 30.6910         | 30.0   | 9.3869  | 5.0522         | 5.0    | 2.2927 | 0.1872          | 0.1705 | 0.1192 |
| Occidente | 550.8028         | 328.2583 | 819.4375 | 162.3121           | 121.3198 | 148.7507 | 0.3712           | 0.394  | 0.1053 | 30.9496         | 31.0   | 9.7184  | 5.0663         | 5.0    | 2.3423 | 0.1852          | 0.1722 | 0.1052 |
| Oriente   | 370.5864         | 237.823  | 478.5524 | 112.4221           | 87.4376  | 92.3882  | 0.3709           | 0.389  | 0.0988 | 30.7236         | 31.0   | 10.3137 | 5.1722         | 5.0    | 2.3753 | 0.1933          | 0.1753 | 0.1145 |
| Sur       | 495.5086         | 319.1446 | 651.4211 | 158.3616           | 118.8863 | 142.5129 | 0.3839           | 0.4029 | 0.0999 | 31.1083         | 31.0   | 9.9659  | 5.0933         | 5.0    | 2.2669 | 0.1884          | 0.1718 | 0.1212 |

| Fabricante      | Ventas_Netas_USD |          |           | Utilidad_Bruta_USD |          |          | Margen_Bruto_Pct |        |        | Riesgo_Stockout |        |        |
|-----------------|------------------|----------|-----------|--------------------|----------|----------|------------------|--------|--------|-----------------|--------|--------|
|                 | mean             | median   | std       | mean               | median   | std      | mean             | median | std    | mean            | median | std    |
|                 |                  |          |           |                    |          |          |                  |        |        |                 |        |        |
| Genfar          | 423.2785         | 330.0077 | 329.5806  | 161.0907           | 122.8181 | 130.5009 | 0.3802           | 0.3881 | 0.0579 | 0.1851          | 0.1667 | 0.1381 |
| Laboratorios MK | 749.0906         | 502.0994 | 725.4097  | 213.1419           | 149.9011 | 188.8728 | 0.2998           | 0.3004 | 0.0609 | 0.2589          | 0.2329 | 0.1454 |
| Procaps         | 721.1104         | 410.1888 | 1033.2989 | 179.089            | 134.2729 | 175.0985 | 0.3307           | 0.3505 | 0.1227 | 0.1918          | 0.1747 | 0.1181 |
| Sanofi          | 291.0319         | 241.5731 | 224.2588  | 119.8059           | 97.6561  | 91.4878  | 0.4146           | 0.4152 | 0.047  | 0.1705          | 0.1602 | 0.0952 |
| Tecnoquímicas   | 374.161          | 312.9281 | 261.2345  | 149.4585           | 120.469  | 99.9686  | 0.4089           | 0.4143 | 0.0707 | 0.1654          | 0.1514 | 0.097  |
| Vitalis         | 225.3037         | 164.4594 | 191.6257  | 107.2657           | 80.097   | 89.7916  | 0.4811           | 0.4839 | 0.0421 | 0.1763          | 0.1666 | 0.0937 |

- Fabricante: Vitalis tiene el mayor margen (48,1%), Laboratorios MK tiene el mayor riesgo de desabasto (25,9%).

# PRINCIPALES PATRONES ENCONTRADOS (ANÁLISIS ESTADÍSTICO) INSIGHTS

## **"Vender más no siempre deja más ganancia"**

Patrón en los datos: Los Distribuidores mueven casi un millón de dólares (USD \$981K), pero su ganancia por venta es baja (margen del 34.6%). En cambio, las Cadenas de Farmacias venden la mitad, pero ganan más por cada producto (margen del 40.6%).

## **"Muchos medicamentos en una sola canasta"**

Patrón en los datos: Procaps se lleva casi la mitad del mercado con el 46.5% de todas las ventas (USD \$1.15M). Sin embargo, Vitalis es el laboratorio más eficiente, logrando un margen de ganancia del 48.1%.

## **"El tiempo destruye el inventario"**

Patrón en los datos: Cuando el proveedor tarda más de 6 días en entregar (Lead Time) y las bodegas tienen menos de 28 días de inventario, el riesgo de quedar sin medicamentos se dispara.

# MODELO

## MODELOS ELEGIDOS PARA EL PROYECTO

### MODELO1: REGRESIÓN LINEAL MULTIPLE

### MODELO2:RANDOM FOREST

PREDICE

Margen Bruto

Riesgo Alto/Bajo

COMPARA

OLS,Ridge, Lasso

Corte por mediana

¿POR QUÉ?

Variable continua

Relaciones no lineales

# Aplicación de los modelos — predicción del margen bruto porcentual

## Modelo 1 — Regresión para la rentabilidad

|                                                          |                                                      |                                                                  |                                                          |
|----------------------------------------------------------|------------------------------------------------------|------------------------------------------------------------------|----------------------------------------------------------|
| <b>1</b><br><b>Variable objetivo</b><br>Margen bruto (%) | <b>2</b><br><b>Predictoras</b><br>9 variables mixtas | <b>3</b><br><b>Preprocesamiento</b><br>One-Hot + Estandarización | <b>4</b><br><b>Entrenamiento</b><br>80% train / 20% test |
|----------------------------------------------------------|------------------------------------------------------|------------------------------------------------------------------|----------------------------------------------------------|

### Variables predictoras

|                  |                   |            |
|------------------|-------------------|------------|
| Tipo institución | Fabricante        | Región     |
| Canal            | Línea terapéutica | Inventario |
| Lead Time        | Descuento         | Devolución |

### Modelos comparados

|                                   |
|-----------------------------------|
| <b>OLS</b><br>Sin regularización  |
| <b>Ridge</b><br>Regularización L2 |
| <b>Lasso</b><br>Regularización L1 |

# Aplicación de los modelos — clasificación del riesgo de desabastecimiento

## Modelo 2 — Random Forest para el riesgo de stockout

|                                                            |                                                      |                                                                        |                                                    |
|------------------------------------------------------------|------------------------------------------------------|------------------------------------------------------------------------|----------------------------------------------------|
| <b>1</b><br><b>Variable objetivo</b><br>Riesgo alto / bajo | <b>2</b><br><b>Punto de corte</b><br>Mediana: 17,29% | <b>3</b><br><b>Predictoras</b><br>Categóricas + inventario + lead time | <b>4</b><br><b>División</b><br>80/20 estratificada |
|------------------------------------------------------------|------------------------------------------------------|------------------------------------------------------------------------|----------------------------------------------------|

### Variables predictoras

|                  |                   |            |
|------------------|-------------------|------------|
| Tipo institución | Fabricante        | Región     |
| Canal            | Línea terapéutica | Inventario |
| Lead Time        |                   |            |

### Algoritmo

|                                                                                                      |
|------------------------------------------------------------------------------------------------------|
| <b>Random Forest Classifier</b><br><br>Clasificación binaria mediante múltiples árboles de decisión. |
|------------------------------------------------------------------------------------------------------|

# EVALUACIÓN DEL MODELO DE REGRESIÓN

MARGEN BRUTO(%) - COMPARACIÓN ENTRE OLS, RIDGE Y LASSO

Registros utilizados en Modelo 1: 5007

|   | Modelo | $R^2$  | MAE    | RMSE   |
|---|--------|--------|--------|--------|
| 0 | OLS    | 0.7016 | 0.0454 | 0.0563 |
| 1 | Ridge  | 0.7016 | 0.0454 | 0.0564 |
| 2 | Lasso  | 0.3566 | 0.0670 | 0.0827 |

- El modelo explica el 70,16% de la variabilidad del margen bruto, con un erro promedio de 4,5 puntos porcentuales



# EVALUACIÓN DEL MODELO RANDOM FOREST

## CLASIFICACIÓN DE RIESGO DE DESABASTECIMIENTO

### MÉTRICAS DE EVALUACIÓN

Accuracy : 0.9710


Precision: 0.9608

Recall : 0.9820

F1-score : 0.9713

Recall de 98,20% en riesgo alto: el modelo identifica 490 de 499 operaciones realmente riesgosas

Variables más importantes:  
Lead\_Time\_Días y Inventario\_Días  
Las variables categoricas son las que más pesan.




### Matriz de confusión

- Verdaderos negativos: 480
- Falsos positivos: 20
- Falsos negativos: 9
- Verdaderos positivos: 490

# CONCLUSIONES Y APRENDIZAJES

- 1.Efectividad del modelado: El margen bruto se predice bien de forma lineal 70.16%, pero predecir el riesgo requiere modelos no lineales como Random Forest (98.2% de efectividad en casos de alto riesgo).
- 2.Volumen no es rentabilidad: Los distribuidores generan los mayores ingresos, pero tienen el margen más bajo (34.6%). Las cadenas de farmacias y laboratorios como Vitalis logran las mejores ganancias por venta (40.6% y 48.1%).
- 3.Riesgo de desabastecimiento: A menor inventario y mayor tiempo de entrega (lead time), aumenta críticamente el riesgo de stockout, afectando la continuidad del servicio al paciente.
- 4.Logística vs. Canal: El riesgo de desabastecimiento depende casi al 100% del tiempo de entrega (lead time) y el inventario disponible en bodega, no del tipo de cliente o canal.



# BIBLIOGRAFÍA

- Villamil, D. (2025). Dataset farmacéutico Colombia. GitHub.  
<https://github.com/dvillamil857/dataset-farmaceutico-colombia>
- Pandas Development Team. (2024). pandas-dev/pandas: Pandas 2.2.0. Zenodo.  
<https://doi.org/10.5281/zenodo.3509134>
- OpenAI. (2026). ChatGPT. <https://chatgpt.com/>

# GRACIAS