

DataXperience

Análisis de rentabilidad y riesgo de desabastecimiento en el sector farmacéutico 2025

Sara Sofía Cruz Fandiño
Martin Felipe Diaz Collas
Sergio David Vargas Sáenz
Julián Fernando Gómez Escobar

PROBLEMA Y OBJETIVOS DEL PROYECTO

Rentabilidad y riesgo de desabastecimiento en el sector farmacéutico colombiano — 2025



PREGUNTA PRINCIPAL

¿Cómo se relacionan el tipo de institución, el fabricante y la ubicación geográfica con la rentabilidad y el riesgo de desabastecimiento de productos farmacéuticos durante 2025?

Objetivos específicos

1

Instituciones

Ventas, rentabilidad y margen bruto según el tipo de institución.

2

Fabricantes

Concentración de ventas y nivel de rentabilidad por fabricante.

3

Ubicación geográfica

Diferencias por ciudad y región en ventas, margen y riesgo.

4

Abastecimiento

Inventario, lead time, riesgo de stockout y productos prioritarios.

BÚSQUEDA Y OBTENCIÓN DE LOS DATOS



1. Fuente de los Datos

Repositorios oficiales en GitHub, APIs REST públicas y Data Lakes de acceso estructurado.



2. Justificación de Elección

Alto volumen de registros limpios, alta frecuencia de actualización y relevancia para el análisis predictivo.




3. Estrategia de Obtención

Pipeline automatizado en Python con scripts modularizados para ingesta, limpieza y validación continua.

BÚSQUEDA Y OBTENCIÓN DE DATOS

DataXperience

1. FUENTE DE DATOS



ORIGEN: Repositorio público GitHub.
METODO: Carga directa vía URL cruda.



AUTOMATION

2. JUSTIFICACIÓN TÉCNICA




CONFIABILIDAD
Misma versión de datos para todos.



AUTOMATIZACIÓN
Reproducibilidad y eficiencia en el pipeline.



INTEGRACIÓN
Formato nativo para Pandas.



ANÁLISIS RÁPIDO
Inmediata etapa de limpieza y EDA.


COMPRENSIÓN DEL CONJUNTO DE DATOS Y VARIABLES

Ventas e inventario de productos farmacéuticos durante 2025

1 Contexto operativo	2 Desempeño financiero	3 Inventario y abastecimiento
Tipo de institución	Ventas	Inventario (días)
Fabricante	Costos	Lead Time (días)
Región	Utilidad bruta	Riesgo de stockout
Canal	Margen bruto (%)	
Línea terapéutica		

Tres dimensiones conectadas: esta combinación de variables permite relacionar el comportamiento comercial, la rentabilidad y el riesgo de desabastecimiento.

PROCESO DE LIMPIEZA Y PREPARACIÓN DE LOS DATOS



1

Duplicados (ID_Registro)

Eliminados para evitar doble conteo en ventas y utilidad.

2

Fechas y meses

Normalizados y validados contra la fecha real.

3

Ciudad y categorías

Unificadas: mayúsculas, tildes, espacios y errores de escritura.

4

Formatos numéricos

Separador decimal corregido y convertido a tipo numérico.

Dataset crudo conservado. La limpieza se trabajó sobre una copia, permitiendo comparar cada transformación.

VENTAS, INSTITUCIÓN Y FABRICANTE

VENTAS NETAS 2025

Octubre

\$244K

mes con mayores ventas


Junio

\$181K

mes con menores ventas


El comportamiento comercial no fue uniforme durante el año: la variación entre el mes más alto y el más bajo fue de 35%.

Margen bruto promedio por tipo de institución



Cadenas: 40.6% · Clínica: 37.8% · Hospital: 37.7% · Distribuidor: 34.6%


Margen bruto promedio por fabricante




Vitalis: 48.1% · Sanofi: 41.5% · Tecnoquímicas: 40.7% · Genfar: 38.1% · Procaps: 33.0% · MK: 30.0%

Análisis exploratorio de datos (EDA) — comportamiento comercial y rentabilidad durante 2025

UBICACIÓN GEOGRÁFICA, INVENTARIO Y LEAD TIME



Centro: \$797K · Occidente: \$591K · Sur: \$430K ·
Norte: \$398K · Oriente: \$266K



Oriente: 19.1% · Centro: 18.8% · Occidente: 18.4%
· Sur: 18.3% · Norte: 18.4%

ANÁLISIS EXPLORATORIO



LEAD TIME → RIESGO



+0,60

Asociación positiva moderada:
mayores tiempos de entrega
tienden a estar asociados con
mayor riesgo.

INVENTARIO → RIESGO

-0,41

Asociación negativa moderada:
mayores niveles de inventario
tienden a estar asociados con
menor riesgo.



Las correlaciones muestran asociación, no causalidad.

ANÁLISIS ESTADISTICO

MEDIDAS DE TENDENCIA CENTRAL Y DISPERSIÓN

	Media	Mediana	Moda
Ventas_Netas_USD	495.327	312.5567	62.7748
Utilidad_Bruta_USD	156.4904	115.8156	26.4748
Margen_Bruto_Pct	0.3806	0.3998	0.1357
Inventario_Días	30.799	31.0	33.0
Lead_Time_Días	5.1023	5.0	5.0
Riesgo_Stockout	0.1894	0.1733	0.2091

Ventas_Netas tiene el coeficiente de variación mas alto(1.39), es la variable mas dispersa.



Media es mayor que la Mediana en Ventas y Utilidad.

	Desviación estándar	Varianza	Mínimo	Máximo	Rango	Q1	Q3	IQR	Coeficiente de variación
Ventas_Netas_USD	688.9173	474607.1068	13.9364	11872.2394	11858.303	176.4398	561.3124	384.8726	1.3908
Utilidad_Bruta_USD	145.02	21030.7905	-348.8216	2681.7326	3030.5541	71.53	191.3677	119.8377	0.9267
Margen_Bruto_Pct	0.1011	0.0102	-0.0516	0.5938	0.6454	0.3175	0.4557	0.1382	0.2655
Inventario_Días	9.8193	96.4178	3.0	68.0	65.0	24.0	37.0	13.0	0.3188
Lead_Time_Días	2.3085	5.3291	1.0	17.0	16.0	3.0	7.0	4.0	0.4524
Riesgo_Stockout	0.12	0.0144	0.0215	2.19	2.1685	0.1203	0.2299	0.1096	0.6332



ANÁLISIS ESTADISTICO

ASIMETRÍA Y VALORES ATÍPICOS



	Skewness	Kurtosis
Ventas_Netas_USD	6.9054	73.6726
Riesgo_Stockout	4.3096	41.6676

	Variable	Q1	Q3	IQR	Límite inferior	Límite superior	Cantidad de atípicos
0	Ventas_Netas_USD	176.4398	561.3124	384.8726	-400.8692	1138.6213	412
5	Riesgo_Stockout	0.1203	0.2299	0.1096	-0.0441	0.3943	196

- Ventas Netas: skewness = 6,9 (el promedio está muy inflado por ventas excepcionalmente altas)
- 412 ventas atípicas operaciones grandes que se salen del patrón normal.
- Riesgo Stockout tiene 196 casos atípicos con riesgo inusualmente alto.

ANÁLISIS ESTADISTICO

DIFERENCIAS ENTRE INSTITUCIONES, FABRICANTES Y REGIONES

Tipo_Institución	Ventas_Netas_USD			Utilidad_Bruta_USD			Margen_Bruto_Pct			Riesgo_Stockout		
	mean	median	std	mean	median	std	mean	median	std	mean	median	std
Cadena de Farmacias	325.8375	228.686	284.8409	117.3378	93.5116	84.4029	0.4061	0.4237	0.0945	0.1852	0.149	0.1697
Clínica	342.5164	242.2745	292.6119	112.991	92.0535	78.9599	0.3785	0.3977	0.1002	0.1888	0.1753	0.0961
Distribuidor	1084.4968	665.1218	1329.2225	297.5087	235.7565	236.442	0.346	0.3681	0.1059	0.1996	0.1908	0.0704
Hospital	428.1435	324.1703	347.6326	145.121	119.7933	100.2556	0.3784	0.3975	0.0981	0.1879	0.1747	0.1006

- Distribuidor: Vende más del doble del promedio (USD 1.084 vs. USD 495) pero tiene el menor margen (34,6%).

- Región: Centro lidera en ventas (USD 554) y margen (39,6%); Oriente tiene el mayor riesgo (19,3%).

Región	Ventas_Netas_USD			Utilidad_Bruta_USD			Margen_Bruto_Pct			Inventario_Días			Lead_Time_Días			Riesgo_Stockout		
	mean	median	std	mean	median	std	mean	median	std	mean	median	std	mean	median	std	mean	median	std
Centro	554.395	368.0098	766.505	187.1528	142.9642	170.4865	0.3962	0.4146	0.0964	30.5892	30.0	9.8238	5.1312	5.0	2.2862	0.1928	0.1747	0.1321
Norte	431.97	272.8084	527.9881	132.8447	99.2817	114.1247	0.3714	0.3934	0.1032	30.6910	30.0	9.3869	5.0522	5.0	2.2927	0.1872	0.1705	0.1192
Occidente	550.8028	328.2583	819.4375	162.3121	121.3198	148.7507	0.3712	0.394	0.1053	30.9496	31.0	9.7184	5.0663	5.0	2.3423	0.1852	0.1722	0.1052
Oriente	370.5864	237.823	478.5524	112.4221	87.4376	92.3882	0.3709	0.389	0.0988	30.7236	31.0	10.3137	5.1722	5.0	2.3753	0.1933	0.1753	0.1145
Sur	495.5086	319.1446	651.4211	158.3616	118.8863	142.5129	0.3839	0.4029	0.0999	31.1083	31.0	9.9659	5.0933	5.0	2.2669	0.1884	0.1718	0.1212

Fabricante	Ventas_Netas_USD			Utilidad_Bruta_USD			Margen_Bruto_Pct			Riesgo_Stockout		
	mean	median	std	mean	median	std	mean	median	std	mean	median	std
Genfar	423.2785	330.0077	329.5806	161.0907	122.8181	130.5009	0.3802	0.3881	0.0579	0.1851	0.1667	0.1381
Laboratorios MK	749.0906	502.0994	725.4097	213.1419	149.9011	188.8728	0.2998	0.3004	0.0609	0.2589	0.2329	0.1454
Procaps	721.1104	410.1888	1033.2989	179.089	134.2729	175.0985	0.3307	0.3505	0.1227	0.1918	0.1747	0.1181
Sanofi	291.0319	241.5731	224.2588	119.8059	97.6561	91.4878	0.4146	0.4152	0.047	0.1705	0.1602	0.0952
Tecnoquímicas	374.161	312.9281	261.2345	149.4585	120.469	99.9686	0.4089	0.4143	0.0707	0.1654	0.1514	0.097
Vitalis	225.3037	164.4594	191.6257	107.2657	80.097	89.7916	0.4811	0.4839	0.0421	0.1763	0.1666	0.0937

- Fabricante: Vitalis tiene el mayor margen (48,1%), Laboratorios MK tiene el mayor riesgo de desabasto (25,9%).

PRINCIPALES PATRONES ENCONTRADOS (ANÁLISIS ESTADÍSTICO) INSIGHTS

"Vender más no siempre deja más ganancia"

Patrón en los datos: Los Distribuidores mueven casi un millón de dólares (USD \$981K), pero su ganancia por venta es baja (margen del 34.6%). En cambio, las Cadenas de Farmacias venden la mitad, pero ganan más por cada producto (margen del 40.6%).

"Muchos medicamentos en una sola canasta"

Patrón en los datos: Procaps se lleva casi la mitad del mercado con el 46.5% de todas las ventas (USD \$1.15M). Sin embargo, Vitalis es el laboratorio más eficiente, logrando un margen de ganancia del 48.1%.

"El tiempo destruye el inventario"

Patrón en los datos: Cuando el proveedor tarda más de 6 días en entregar (Lead Time) y las bodegas tienen menos de 28 días de inventario, el riesgo de quedar sin medicamentos se dispara.



MODELO

MODELOS ELEGIDOS PARA EL PROYECTO

MODELO1: REGRESIÓN LINEAL MULTIPLE

MODELO2:RANDOM FOREST

PREDICE

Margen Bruto

Riesgo Alto/Bajo

COMPARA

OLS,Ridge, Lasso

Corte por mediana

¿POR QUÉ?

Variable continua

Relaciones no lineales

Aplicación de los modelos — predicción del margen bruto porcentual

Modelo 1 — Regresión para la rentabilidad

1 Variable objetivo Margen bruto (%)	2 Predictoras 9 variables mixtas	3 Preprocesamiento One-Hot + Estandarización	4 Entrenamiento 80% train / 20% test
--	--	--	--

Variables predictoras

Tipo institución	Fabricante	Región
Canal	Línea terapéutica	Inventario
Lead Time	Descuento	Devolución

Modelos comparados

OLS Sin regularización
Ridge Regularización L2
Lasso Regularización L1

Aplicación de los modelos — clasificación del riesgo de desabastecimiento

Modelo 2 — Random Forest para el riesgo de stockout

1 Variable objetivo Riesgo alto / bajo	2 Punto de corte Mediana: 17,29%	3 Predictoras Categóricas + inventario + lead time	4 División 80/20 estratificada
--	--	--	--

Variables predictoras

Tipo institución	Fabricante	Región
Canal	Línea terapéutica	Inventario
Lead Time		

Algoritmo

Random Forest Classifier Clasificación binaria mediante múltiples árboles de decisión.
--

EVALUACIÓN DEL MODELO DE REGRESIÓN

MARGEN BRUTO(%) - COMPARACIÓN ENTRE OLS, RIDGE Y LASSO

Registros utilizados en Modelo 1: 5007

	Modelo	R ²	MAE	RMSE
0	OLS	0.7016	0.0454	0.0563
1	Ridge	0.7016	0.0454	0.0564
2	Lasso	0.3566	0.0670	0.0827

- El modelo explica el 70,16% de la variabilidad del margen bruto, con un erro promedio de 4,5 puntos porcentuales



EVALUACIÓN DEL MODELO RANDOM FOREST

CLASIFICACIÓN DE RIESGO DE DESABASTECIMIENTO

MÉTRICAS DE EVALUACIÓN

Accuracy : 0.9710


Precision: 0.9608

Recall : 0.9820

F1-score : 0.9713

Recall de 98,20% en riesgo alto: el modelo identifica 490 de 499 operaciones realmente riesgosas

Variables más importantes:
Lead_Time_Días y Inventario_Días
Las variables categoricas son las que más pesan.




Matriz de confusión

- Verdaderos negativos: 480
- Falsos positivos: 20
- Falsos negativos: 9
- Verdaderos positivos: 490

CONCLUSIONES Y APRENDIZAJES

- 1.Efectividad del modelado: El margen bruto se predice bien de forma lineal 70.16%, pero predecir el riesgo requiere modelos no lineales como Random Forest (98.2% de efectividad en casos de alto riesgo).
- 2.Volumen no es rentabilidad: Los distribuidores generan los mayores ingresos, pero tienen el margen más bajo (34.6%). Las cadenas de farmacias y laboratorios como Vitalis logran las mejores ganancias por venta (40.6% y 48.1%).
- 3.Riesgo de desabastecimiento: A menor inventario y mayor tiempo de entrega (lead time), aumenta críticamente el riesgo de stockout, afectando la continuidad del servicio al paciente.
- 4.Logística vs. Canal: El riesgo de desabastecimiento depende casi al 100% del tiempo de entrega (lead time) y el inventario disponible en bodega, no del tipo de cliente o canal.



BIBLIOGRAFÍA

- Villamil, D. (2025). Dataset farmacéutico Colombia. GitHub.
<https://github.com/dvillamil857/dataset-farmaceutico-colombia>
- Pandas Development Team. (2024). pandas-dev/pandas: Pandas 2.2.0. Zenodo.
<https://doi.org/10.5281/zenodo.3509134>
- Ilustración de Conclusiones y Logística: Generada mediante Inteligencia Artificial (Google Gemini / Imagen), 2026. Prompt: Síntesis gráfica sobre validación de datos, rentabilidad por canal y gestión de stockout.
- Imágenes de Stock y Productos Farmacéuticos: Fotografía publicitaria y de inventario seleccionada del archivo interno del proyecto DataXperience.

GRACIAS